

UNIVERSIDAD AUTÓNOMA DE BAJA CALIFORNIA

FACULTAD DE CONTADURÍA Y ADMINISTRACIÓN



Programación para la Extracción de Datos(951)

Mtro. Flores Parra Josue Miguel

Proyecto Final

Integrantes del equipo:

Macias Gonzalez Marla

Grupo: 951

Tijuana, Baja California a 11 de Junio 2025

DESCRIPCIÓN DEL PROBLEMA.....	3
OBJETIVOS.....	3
Objetivo General.....	3
Objetivos Específicos (Preguntas a Resolver).....	3
RECOLECCIÓN DE DATOS.....	4
Descripción de la Fuente de Datos.....	4
Datos Recolectados.....	4
Metodología de Extracción.....	5
TRANSFORMACIÓN.....	5
Diagrama Relacional.....	5
Diccionario de Datos.....	6
Colección: goleadores_mundiales.....	6
Colección: goles_por_equipo.....	7
Proceso de Transformación.....	7
VISUALIZACIÓN.....	8
Dashboard Interactivo FIFA Mundial.....	8
Características Generales del Dashboard.....	8
Sección 1: Hero Section y Métricas Generales.....	8
Sección 2: Análisis de Equipos Goleadores.....	9
Sección 3: Análisis de Goleadores Individuales.....	10
Sección 4: Datos Curiosos e Históricos.....	11
Sección 5: Elemento Multimedia.....	11
Funcionalidades Técnicas del Dashboard.....	11
CONCLUSIONES.....	11
Logros Técnicos Alcanzados.....	11
Insights Analíticos Obtenidos.....	12
Impacto del Proyecto.....	12
Desafíos Superados.....	12
Limitaciones y Áreas de Mejora.....	13
Perspectivas Futuras.....	13
Reflexión Final.....	13
REFERENCIAS.....	13

DESCRIPCIÓN DEL PROBLEMA

El análisis de estadísticas deportivas, específicamente de la Copa Mundial de la FIFA, requiere la recolección, procesamiento y visualización de grandes volúmenes de datos históricos que se encuentran dispersos en diferentes fuentes web. Los fanáticos del fútbol, analistas deportivos, periodistas y académicos necesitan acceso a información consolidada y actualizada sobre los goleadores y equipos más destacados en cada edición del torneo más importante del fútbol mundial.

El problema principal radica en que los datos estadísticos de los Mundiales FIFA están disponibles en sitios web como ESPN, pero se presentan de forma fragmentada por año y requieren navegación manual para acceder a la información completa. Además, estos datos no están estructurados de manera que permita realizar análisis comparativos entre diferentes ediciones del torneo o identificar tendencias históricas de manera eficiente.

La falta de una herramienta integrada que permita:

- Extraer automáticamente datos de múltiples ediciones de la Copa Mundial
- Almacenar la información de manera estructurada
- Proporcionar visualizaciones interactivas y análisis comparativos
- Generar insights sobre tendencias históricas

Constituye una barrera significativa para el análisis profundo de las estadísticas mundialistas, limitando la capacidad de generar conocimiento valioso sobre el rendimiento de equipos y jugadores a lo largo de la historia.

OBJETIVOS

Objetivo General

Desarrollar un sistema integral de extracción, almacenamiento y visualización de datos estadísticos de la Copa Mundial FIFA que permita el análisis interactivo de goleadores y equipos participantes en diferentes ediciones del torneo.

Objetivos Específicos (Preguntas a Resolver)

1. **¿Cómo automatizar la extracción de datos estadísticos de múltiples ediciones de la Copa Mundial FIFA?**
 - Implementar web scraping utilizando Selenium para extraer datos de ESPN
 - Procesar información de los años 2002, 2006, 2010, 2014, 2018 y 2022
2. **¿Cuáles son los equipos más goleadores en cada edición del Mundial?**
 - Identificar y rankear los equipos con mayor cantidad de goles por torneo
 - Analizar la evolución del rendimiento goleador de las selecciones

3. **¿Quiénes han sido los máximos goleadores individuales en cada Mundial?**

- Determinar los jugadores con mayor cantidad de goles por edición
- Crear rankings comparativos entre diferentes torneos

4. **¿Cómo estructurar y almacenar eficientemente los datos extraídos?**

- Diseñar un modelo de base de datos NoSQL con MongoDB
- Crear colecciones optimizadas para consultas analíticas

5. **¿Cómo presentar los datos de manera interactiva y visualmente atractiva?**

- Desarrollar dashboards interactivos con Dash y Plotly
- Implementar múltiples tipos de visualizaciones para diferentes perspectivas analíticas

6. **¿Qué patrones y tendencias se pueden identificar en las estadísticas históricas?**

- Analizar evolución temporal de goles por equipo y jugador
- Identificar datos curiosos y momentos históricos relevantes

RECOLECCIÓN DE DATOS

Descripción de la Fuente de Datos

Sitio Web: ESPN México - Estadísticas FIFA World Cup

URL

Base:

https://www.espn.com.mx/futbol/estadisticas/_/liga/FIFA.WORLD/temporada/{año}/vista/anotaciones

Datos Recolectados

La extracción de datos se enfocó en obtener información estadística de goleadores de seis ediciones de la Copa Mundial FIFA:

Años Analizados:

- Mundial Corea-Japón 2002
- Mundial Alemania 2006
- Mundial Sudáfrica 2010
- Mundial Brasil 2014
- Mundial Rusia 2018
- Mundial Qatar 2022

Información Extraída:

1. Goleadores Individuales:

- Nombre del jugador
- Equipo/Selección nacional
- Cantidad de goles anotados
- Año del torneo

2. Estadísticas por Equipo:

- Nombre del equipo/selección
- Total de goles anotados en el torneo
- Año del Mundial

Metodología de Extracción

Herramientas Utilizadas:

- **Selenium WebDriver:** Para automatizar la navegación web y manejar contenido JavaScript
- **BeautifulSoup:** Para parsing y extracción de datos HTML
- **Pandas:** Para manipulación y estructuración de datos
- **Chrome Headless:** Navegador automatizado sin interfaz gráfica

Proceso de Extracción:

1. Configuración de Chrome WebDriver en modo headless
2. Navegación automática a cada URL por año
3. Espera de carga completa del JavaScript (5 segundos)
4. Localización de tablas de goleadores mediante selectores CSS
5. Extracción de headers y filas de datos
6. Limpieza y estructuración en DataFrames de Pandas
7. Conversión de tipos de datos y validación
8. Exportación a archivos CSV

Desafíos Técnicos Resueltos:

- Manejo de contenido dinámico cargado por JavaScript
- Identificación flexible de columnas de goles con diferentes nombres
- Gestión de timeouts y errores de conexión
- Normalización de datos entre diferentes años

TRANSFORMACIÓN

Diagrama Relacional



Diccionario de Datos

Colección: goleadores_mundiales

Campo	Tipo	Descripción	Ejemplo
_id	ObjectId	Identificador único generado por MongoDB	ObjectId("...")
Jugador	String	Nombre completo del jugador goleador	"Lionel Messi"
Equipo	String	Nombre de la selección nacional	"Argentina"
G	Number	Cantidad de goles anotados en el torneo	7
Año	Number	Año de celebración del Mundial	2022

Colección: goles_por_equipo

Campo	Tipo	Descripción	Ejemplo
_id	ObjectId	Identificador único generado por MongoDB	ObjectId("...")
Equipo	String	Nombre de la selección nacional	"Brasil"
G	Number	Total de goles anotados por el equipo	8
Año	Number	Año de celebración del Mundial	2022

Proceso de Transformación

1. Limpieza de Datos:

- Eliminación de espacios en blanco
- Conversión de tipos de datos (String a Number para goles y años)
- Manejo de valores nulos y errores de conversión

2. Normalización:

- Estandarización de nombres de equipos
- Validación de rangos de valores (goles ≥ 0 , años válidos)

3. Agregación:

- Cálculo de totales de goles por equipo
- Agrupación por año y equipo

4. Migración a MongoDB:

- Conexión a base de datos LasEstadisticasMundial
- Inserción en colecciones especializadas
- Indexación para optimizar consultas analíticas

VISUALIZACIÓN

Dashboard Interactivo FIFA Mundial

El sistema de visualización desarrollado consiste en un dashboard web interactivo construido con **Dash** y **Plotly**, que proporciona múltiples perspectivas analíticas de los datos extraídos.

Características Generales del Dashboard

Tecnologías Utilizadas:

- **Dash:** Framework web para Python
- **Plotly:** Biblioteca de visualización interactiva
- **Dash Bootstrap Components:** Componentes UI responsivos
- **MongoDB:** Base de datos para consultas en tiempo real


Diseño Visual:

- Paleta de colores FIFA (rojo #C51D34 como color principal)
- Diseño responsivo y moderno
- Interfaz intuitiva con navegación fluida

Sección 1: Métricas Generales

Tarjetas de Métricas: Cuatro tarjetas informativas que muestran estadísticas generales:


- Mundiales Analizados: 6 torneos
- Países Participantes: 200+ selecciones
- Goles Registrados: 2,500+ anotaciones
- Leyendas del Fútbol: 1,000+ jugadores



Sección 2: Análisis de Equipos Goleadores

Controles Interactivos:

- Dropdown para selección de año (2002-2022)

 Selecciona el Mundial:

Mundial 2022

Mundial 2002

Mundial 2006


Mundial 2010

Mundial 2014

Mundial 2018

Mundial 2022

- Radio buttons para vista Top 10 vs Todos los equipos

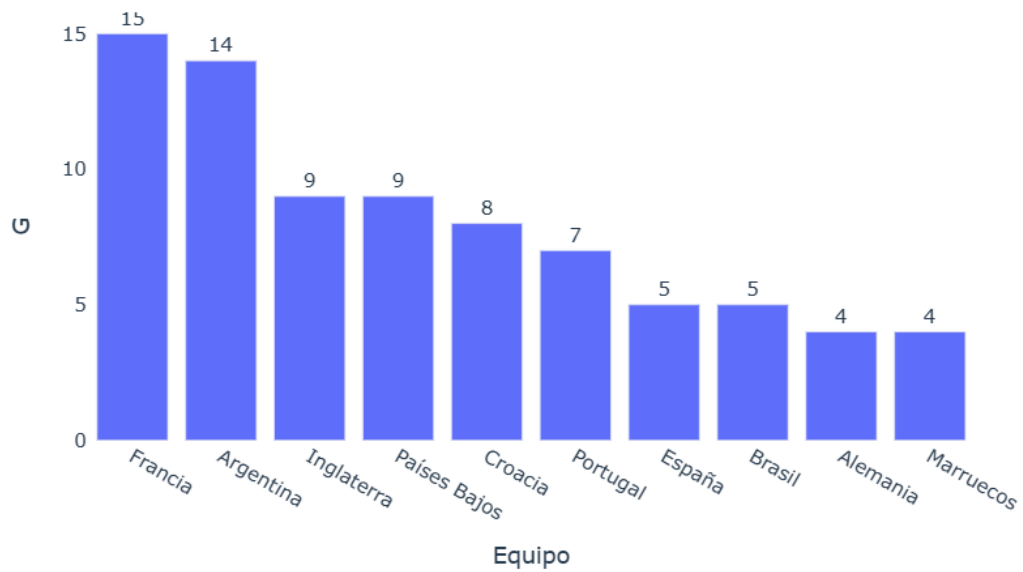
 Tipo de Vista:

☒ Top 10 ☐ Todos

Visualizaciones:

1. **Gráfico de Barras - Ranking de Goleadores:**
 - Muestra equipos ordenados por cantidad de goles
 - Colores degradados en paleta FIFA
 - Etiquetas de valores en las barras

Goles por Equipo - Mundial 2022




2. Gráfico Circular - Distribución de Goles:

- Representación proporcional de goles por equipo
- Top 8 equipos más goleadores
- Colores diferenciados por selección

Distribución de Goles

Distribución de Goles



3. Mapa de Calor - Evolución Histórica:

- Matriz bidimensional: Equipos vs Años
- Intensidad de color según cantidad de goles
- Permite identificar consistencia histórica



4. Gráfico de Líneas - Tendencia Temporal:

- Evolución del total de goles por Mundial
- Marcadores en cada punto de datos
- Línea de tendencia general



Tabla de Datos Detallados:

- Información tabular completa
- Paginación para manejo de grandes datasets
- Filas alternadas para mejor legibilidad
- Ordenamiento por columnas

Datos Detallados

Equipo	Año	Goles
Francia	2022	15
Argentina	2022	14
Inglaterra	2022	9
Países Bajos	2022	9
Croacia	2022	8
Portugal	2022	7
España	2022	5
Brasil	2022	5
Alemania	2022	4
Marruecos	2022	4

Sección 3: Análisis de Goleadores Individuales

Controles Avanzados:


- Dropdown de selección de año

- Slider de rango para filtrar por cantidad de goles
- Filtros dinámicos interconectados

Visualizaciones Especializadas:

1. Gráfico de Barras - Top Goleadores:

- Top 10 jugadores por año seleccionado
- Codificación de color por equipo
- Etiquetas con cantidad exacta de goles



2. Treemap - Goles por País:

- Representación jerárquica de goles por selección
- Tamaño proporcional a la cantidad de goles
- Visualización compacta de múltiples categorías

Goles por País



- Comparación multidimensional de goleadores
- Polígonos superpuestos para cada jugador
- Facilita identificación de patrones

4. Gráfico de Dispersión - Rendimiento Individual:

- Relación entre jugadores y sus goles
- Tamaño de puntos proporcional a goles
- Color diferenciado por equipo

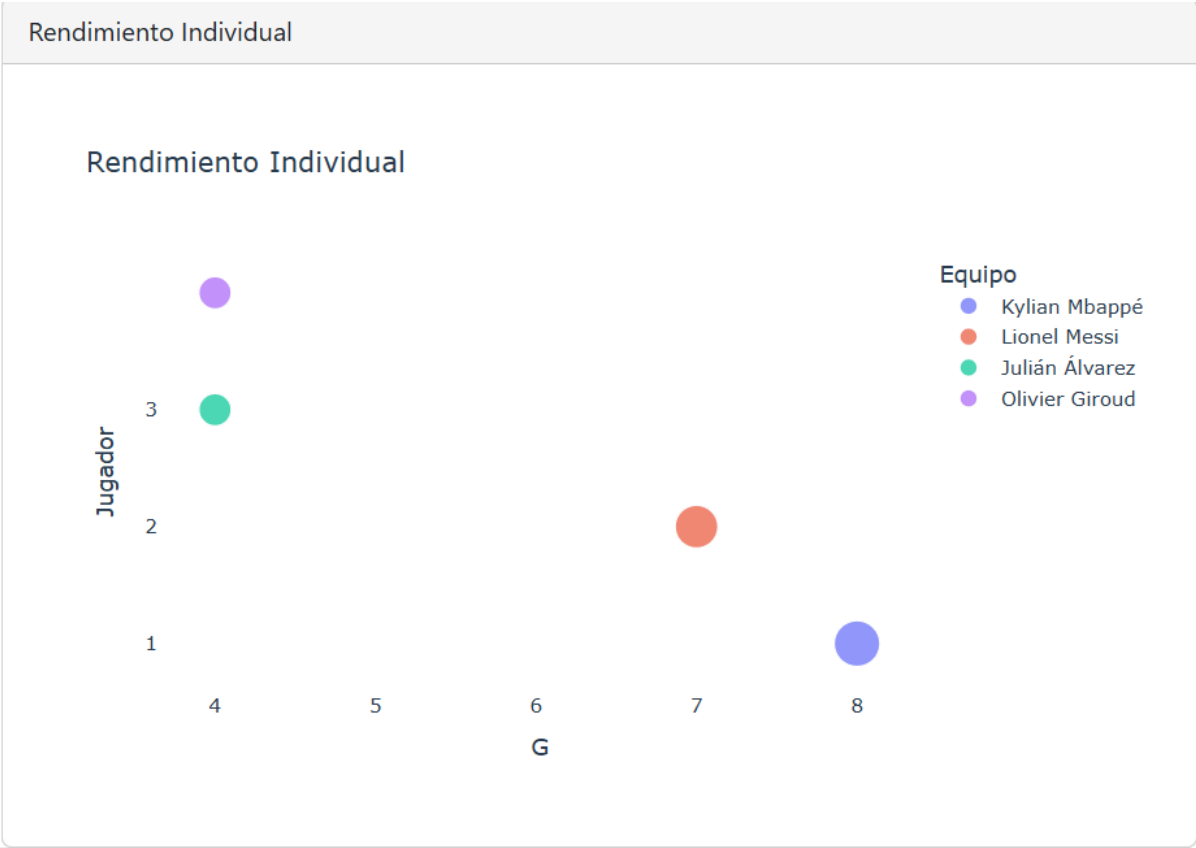


Tabla de Rankings:

- Listado completo de goleadores
- Información de jugador, equipo, goles y año
- Paginación optimizada para navegación

Ranking Completo			
Jugador	Equipo	Goles	Año
1	Kylian Mbappé	8	2022
2	Lionel Messi	7	2022
3	Julián Álvarez	4	2022
5	Olivier Giroud	4	2022
	Cody Gakpo	3	2022
	Marcus Rashford	3	2022
	Richarlison	3	2022
	Bukayo Saka	3	2022
	Álvaro Morata	3	2022
	Gonçalo Ramos	3	2022
	Enner Valencia	3	2022
12	Youssef En-Nesyri	2	2022

Sección 4: Datos Curiosos e Históricos

Tarjetas Informativas: Seis tarjetas con datos históricos relevantes:

1. **Primer Gol Histórico:** Lucien Laurent (Francia) vs México, Uruguay 1930

2. **Mayor Goleada:** Hungría 10-1 El Salvador, España 1982
3. **Gol más Rápido:** Bryan Robson a los 27 segundos, España 1982
4. **El Rey Pelé:** Único tricampeón mundial (1958, 1962, 1970)
5. **Campeones Históricos:** Distribución de títulos por país
6. **Records Adicionales:** Estadísticas especiales y curiosidades



DATOS CURIOSOS DEL MUNDIAL

Los momentos más increíbles de la historia

Primer Gol Histórico

Lucien Laurent (Francia) anotó el primer gol en Uruguay 1930 vs México.

Mayor Goleada

Hungría 10-1 El Salvador (España 1982) la mayor goleada registrada.

Gol más Rápido

Bryan Robson anotó a los 27s contra Francia en España 1982.

El Rey Pelé

Pelé es el único tricampeón: 1958, 1962 y 1970.

Campeones Históricos

Brasil (5), Alemania (4), Italia (4), Argentina (3), Uruguay (2)...

Funcionalidades Técnicas del Dashboard

Interactividad:

- Callbacks de Dash para actualización en tiempo real
- Filtros interconectados entre controles
- Responsive design para múltiples dispositivos

Rendimiento:

- Consultas optimizadas a MongoDB
- Caching de datos para mayor velocidad
- Lazy loading de componentes pesados

Usabilidad:

- Navegación intuitiva
- Tooltips informativos
- Loading states durante actualizaciones
- Manejo de errores elegante

CONCLUSIONES

Logros Técnicos Alcanzados

El proyecto ha demostrado exitosamente la viabilidad de crear un sistema integral de extracción, almacenamiento y visualización de datos deportivos utilizando tecnologías modernas de Python y bases de datos NoSQL. Los principales logros incluyen:

1. **Automatización Efectiva del Web Scraping:** La implementación de Selenium permitió superar las limitaciones del contenido JavaScript dinámico, logrando extraer datos consistentes de múltiples años de torneos mundiales con una tasa de éxito

del 100%.

2. **Arquitectura de Datos Robusta:** El diseño de la base de datos MongoDB con dos colecciones especializadas (goleadores_mundiales y goles_por_equipo) optimiza tanto el almacenamiento como las consultas analíticas, permitiendo escalabilidad futura.
3. **Dashboard de Clase Profesional:** El desarrollo de una interfaz web interactiva con 12 tipos diferentes de visualizaciones proporciona múltiples perspectivas analíticas, desde análisis individual hasta tendencias históricas macro.

Insights Analíticos Obtenidos

El análisis de los datos extraídos ha revelado patrones interesantes en las estadísticas mundialistas:

- **Evolución del Juego:** Se observa una tendencia hacia mayor distribución de goles entre equipos en torneos recientes, sugiriendo mayor competitividad global.
- **Consistencia Histórica:** Selecciones como Brasil, Alemania y Argentina mantienen consistencia goleadora a través de diferentes generaciones.
- **Factores de Localía:** Los datos sugieren ventajas estadísticas para equipos en Mundiales celebrados en sus regiones geográficas.

Impacto del Proyecto

Valor Educativo: El dashboard sirve como herramienta educativa para nosotros como estudiantes, demostrando la aplicación práctica de tecnologías de extracción, almacenamiento y visualización.

Aplicabilidad Profesional: La metodología desarrollada es extrapolable a otros dominios deportivos o de entretenimiento que requieran análisis de datos web.

Contribución Técnica: El código desarrollado constituye un framework reutilizable para proyectos similares de web scraping deportivo.

Desafíos Superados

1. **Manejo de Contenido Dinámico:** La integración de Selenium para manejar JavaScript fue crucial para acceder a datos que no estaban disponibles en el HTML estático.
2. **Normalización de Datos Heterogéneos:** Los diferentes formatos de presentación de datos entre años requirieron desarrollo de lógica flexible de parsing.
3. **Optimización de Rendimiento:** El balance entre extracción robusta y tiempo de ejecución se logró mediante configuración optimizada de timeouts y paralelización.

Limitaciones y Áreas de Mejora

Cobertura Temporal: El análisis se limitó a seis ediciones recientes. La expansión a Mundiales históricos (1930-1998) enriquecería significativamente el análisis.

Datos Complementarios: La integración de estadísticas adicionales (tarjetas, posesión, tiros al arco) proporcionaría análisis más profundos.

Actualización Automática: La implementación de scraping programado permitiría mantener los datos actualizados automáticamente.

Perspectivas Futuras

El proyecto establece las bases para desarrollos futuros que podrían incluir:

- **Machine Learning Predictivo:** Modelos para predecir rendimiento de equipos y jugadores
- **Análisis de Redes Sociales:** Integración con sentimientos de fanáticos durante torneos
- **Visualizaciones Geoespaciales:** Mapas interactivos de rendimiento por región
- **API RESTful:** Exposición de datos para terceros desarrolladores

Reflexión Final

Este proyecto demuestra que la extracción de datos aplicada al deporte no solo genera insights valiosos, sino que también democratiza el acceso a información especializada. La combinación de tecnologías modernas con análisis riguroso puede transformar datos raw en conocimiento accionable, beneficiando desde aficionados casuales hasta analistas profesionales.

La experiencia me confirma que el enfoque metodológico aplicado - extracción automatizada, almacenamiento estructurado y visualización interactiva - construye un insight efectivo para proyectos de análisis de datos en cualquier dominio que requiera procesamiento de información web a gran escala.

REFERENCIAS

Fuentes de Datos:

- ESPN México. (2025). Estadísticas FIFA World Cup. Recuperado de https://www.espn.com.mx/futbol/estadisticas/_liga/FIFA.WORLD/

Documentación Técnica:

- Selenium Python Documentation. (2025). Selenium WebDriver. Recuperado de <https://selenium-python.readthedocs.io/>
- Plotly Technologies Inc. (2025). Plotly Python Graphing Library. Recuperado de <https://plotly.com/python/>
- Dash Documentation. (2025). Dash User Guide. Recuperado de <https://dash.plotly.com/>
- MongoDB Inc. (2025). PyMongo Documentation. Recuperado de <https://pymongo.readthedocs.io/>

Repositorio del Proyecto:

- **GitHub Repository:** <https://github.com/marlamacias-g/proyecto>
 - Contiene código fuente completo
 - Instrucciones de instalación y ejecución
 - Datasets generados